



به نام خدا
دانشگاه تهران



دانشکده مهندسی برق و کامپیوتر

درس شبکه‌های عصبی و یادگیری عمیق

تمرین شماره دو

طراحان تمرین:

سوال یک: علیرضا آخوندی

سوال دو: فاطمه پاکدامن

مهلت ارسال: ۲۵ آبان ۱۴۰۴

3	سوال ۱. تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی
3	۱-۱. آماده‌سازی مجموعه داده (۵ امتیاز)
3	۲-۱. پیش‌پردازش داده‌ها (۲۰ امتیاز)
4	۳-۱. مدل AlexNet
4	۱-۳-۱. پیاده‌سازی (۲۰ امتیاز)
5	۲-۳-۱. نتایج و ارزیابی (۱۵ امتیاز)
5	۴-۱. مدل پیشنهادی مقاله
5	۱-۴-۱. پیاده‌سازی (۲۰ امتیاز)
6	۲-۴-۱. نتایج و ارزیابی (۲۰ امتیاز)
7	سوال ۲. طبقه‌بندی صحنه در تصاویر سنجش از دور
7	۱-۱. آماده‌سازی مجموعه داده (۱۰ امتیاز)
7	۲-۱. پیش‌پردازش داده‌ها (۱۵ امتیاز)
8	۳-۱. پیاده‌سازی (۲۰ امتیاز)
9	۴-۱. ارزیابی (۳۰ امتیاز)
9	۵-۱. تحلیل و بهینه‌سازی
9	۱-۵-۱. تأثیر داده‌افزایی (۱۰ امتیاز)
10	۲-۵-۱. نقش بهینه‌ساز (۱۰ امتیاز)
10	۳-۵-۱. بهینه‌سازی توسط fine-tuning (۱۰ امتیاز)

سوال ۱. تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی

توسعه روز افزون تکنیک‌های یادگیری عمیق برای طبقه‌بندی تصاویر باعث شده‌است که در حوزه‌های مختلف به عنوان راه‌حل استفاده شوند. طبقه‌بندی بیماری گیاهان از روی تصاویر برگ‌های آن‌ها یکی از مسائلی هست که توجه محققین را به خود جلب کرده و مقالات زیادی با تمرکز بر روی معماری‌های شبکه مختلف در این زمینه منتشر شده‌اند. در این [مقاله](#)، به کاربرد شبکه‌های عصبی کانولوشنی^۱ برای شناسایی بیماری برگ برنج پرداخته شده‌است. هدف اصلی پژوهش ارائه یک مدل خودکار و دقیق برای شناسایی زود هنگام بیماری‌های گیاهان است که می‌تواند به بهبود کیفیت و افزایش بازدهی محصولات کشاورزی کمک کند. بیماری‌های گیاهان، از جمله مشکلاتی هستند که می‌توانند به کاهش محصول منجر شوند. شناسایی به موقع این بیماری‌ها اهمیت بالایی در جلوگیری از خسارت به محصولات دارد.

هدف این تمرین، پیاده‌سازی و مقایسه معماری ارائه شده در مقاله با یک مدل ساده شبکه CNN و تأثیر استفاده از یادگیری انتقالی^۲ در افزایش سرعت یادگیری و دقت طبقه‌بندی است.

۱-۱. آماده‌سازی مجموعه داده (۵ امتیاز)

در این بخش به آماده‌سازی مجموعه داده می‌پردازیم. در ابتدا، مجموعه داده را از سایت [Kaggle](#) دریافت کنید. پس از دریافت مجموعه داده، کلاس Healthy Rice Leaf را به همراه داده‌های سه کلاس دلخواه دیگر جدا کرده و به سه بخش آموزش، تست و ارزیابی به نسبت ۷۰-۱۵-۱۵ جدا کنید. توزیع داده‌های هر کلاس را بررسی کنید و یک هیستوگرام از تعداد داده‌های هر کلاس رسم کنید.

برای دانلود مجموعه داده در محیط Google Colab یا Kaggle می‌توانید از کد زیر استفاده کنید.

```
import kagglehub
path = kagglehub.dataset_download("anshulm257/rice-disease-dataset")
```

۱-۲. پیش‌پردازش داده‌ها (۲۰ امتیاز)

در این گام به آماده‌سازی مجموعه داده با کمک داده‌افزایی^۳ می‌پردازیم. داده‌افزایی یعنی تولید نمونه‌های آموزشی جدید از داده‌های موجود با اعمال تبدیلی‌هایی که برچسب داده را تغییر نمی‌دهند؛ مانند چرخش و برش، وارون‌سازی و

^۱ Convolutional Neural Network

^۲ Transfer Learning

^۳ Data Augmentation

جابه‌جایی، تغییر مقیاس و کادر، تغییرات نوری یا رنگی، نویز، محوشدگی تا تنوع داده‌ها بدون جمع‌آوری برچسب‌های تازه افزایش یابد. در طبقه‌بندی تصویر با CNN این کار حیاتی است چون اندازه مؤثر دیتاست را بزرگ می‌کند، بیش‌برازش را کاهش می‌دهد، و شبکه را نسبت به تغییرات رایج دنیای واقعی (زاویه دید، نور، پس‌زمینه) نامتغیر و مقاوم می‌سازد؛ نتیجه‌اش تعمیم بهتر، دقت بالاتر روی داده‌های دیده‌نشده و استفاده بهینه از داده‌های برچسب‌خورده محدود است. برای آشنایی بیشتر پیشنهاد می‌شود به این [لینک](#) مراجعه شود.

لازم به ذکر است که داده‌افزایی تنها بر روی مجموعه داده آموزش انجام می‌شود. چون ممکن است تغییراتی بسازیم که در دنیای واقعی وجود ندارند و مدل آن الگوهای غیرواقعی را یاد بگیرد. در نتیجه، مدل روی داده افزوده شده خوب عمل می‌کند اما روی داده واقعی ضعیف می‌شود. برای اینکه ارزیابی دقیق و قابل اعتماد باشد، داده‌های تست و ارزیابی باید نمونه‌های واقعی و دست‌نخورده را نشان بدهند تا عملکرد مدل تحت تأثیر تغییرات مصنوعی قرار نگیرد. در واقع این کار امکان بررسی این که آیا داده‌افزایی مؤثر بوده یا خیر را به ما می‌دهد.

برای این بخش، پیش‌پردازش‌های زیر را انجام دهید:

- طبق مقاله اندازه تصاویر را به 224×224 تغییر دهید.
 - پس از تغییر سایز تصاویر به ابعاد خواسته شده، مقادیر پیکسلی را بین ۰ و ۱ تبدیل کنید.
 - تعدادی از روش‌های داده‌افزایی (حداقل سه روش) را که برای مجموعه داده مناسب هستند انتخاب کنید و دلیل انتخاب‌های خود را بیان کنید. پیشنهاد می‌شود برای این بخش به مقاله مراجعه شود و از روش‌های ذکر شده برای این کار استفاده شود. این بخش فقط بر روی مجموعه داده آموزش باید انجام شود.
- پس از اتمام مراحل، تعدادی از تصاویر مجموعه داده را به دلخواه انتخاب کرده و تصاویر تولید شده پس از اعمال داده‌افزایی را در گزارش نمایش دهید.

۱-۳. مدل AlexNet

۱-۳-۱. پیاده‌سازی (۲۰ امتیاز)

در این بخش، مدل AlexNet را از ابتدا و به صورت دستی پیاده‌سازی خواهیم کرد. در اسلایدهای درس با مدل AlexNet آشنا شده‌اید؛ اکنون هدف شما نوشتن کد معماری و آموزش آن روی مجموعه داده‌ی فراهم شده است. پس از تکمیل پیاده‌سازی، یک summary از مدل تهیه و ارائه کنید. برای آموزش شبکه ۳۰ ایپاک کافی است. نرخ یادگیری مناسب را بدست آورید و به همراه ابر پارامترهای دیگر گزارش کنید. دلیل انتخاب‌های خود را بنویسید.

۱-۳-۲. نتایج و ارزیابی (۱۵ امتیاز)

موارد زیر را بدست آورید:

- نمودار تغییرات خطا و دقت بر روی مجموعه داده ارزیابی را در طول آموزش گزارش و تحلیل کنید.
- معیارهای Accuracy، Sensitivity و Specificity (تعریف معیارها در مقاله آمده است) را روی مجموعه داده تست محاسبه و مانند جدول ۴ مقاله گزارش کنید و مقادیر بدست آمده را با توجه به تعاریف آن‌ها به صورت مفهومی تحلیل کنید و توضیح دهید که هر کدام چه دیدی از عملکرد مدل آموزش دیده به ما می‌دهد.
- ماتریس درهم‌بختگی^۴ را برای مجموعه‌ی تست گزارش کنید و بررسی کنید که کدام کلاس‌ها بیشترین/کمترین تشخیص درست را دارند و جفت کلاس‌های پرتداخل کدامند.

۱-۴-۴. مدل پیشنهادی مقاله

۱-۴-۱. پیاده‌سازی (۲۰ امتیاز)

در این بخش به پیاده‌سازی مدل مقاله می‌پردازیم. در این بخش به طور خاص با مفهوم یادگیری انتقالی^۵ آشنا خواهید شد. برای پیاده‌سازی معماری پیشنهادی مقاله، بخشی از لایه‌های ابتدایی را مدل VGG19، که بر روی مجموعه داده ImageNet آموزش داده شده است، تشکیل خواهند داد و در طول یادگیری نیز وزن‌های این بخش فریز می‌شوند. برای انجام این بخش مطابق با توضیحات مقاله مدل پیشنهادی را پیاده‌سازی و آموزش دهید.

دقت کنید که به دلیل استفاده از مدل پیش‌آموزش داده شده باید با یک تغییر نسبت به تغییرات انجام شده در بخش ۱-۲ دوباره پیش‌پردازش را برای این بخش انجام دهید. اگر از یک شبکه پایه از پیش‌آموزش دیده (مثل VGG آموزش دیده روی ImageNet) استفاده و آن را فریز می‌کنید، باید دقیقاً از همان میانگین و انحراف معیار مجموعه داده‌ای که مدل بر روی آن آموزش داده شده، استفاده کنید تا «شیفت توزیع» رخ ندهد؛ چون لایه‌های فریز شده نمی‌توانند خود را با مقیاس جدید وفق دهند. همچنین، باید همان نرمال‌سازی را برای مجموعه داده ارزیابی و تست هم به کار ببرید. بنابراین در این بخش نورمالیزیشن مقادیر پیکسل‌ها را با توجه به مقادیر میانگین و انحراف معیار مجموعه داده ImageNet به مراحل پیش‌پردازش اضافه کنید. برای دسترسی به مقادیر ذکر شده و همچنین برای مطالعه بیشتر می‌توانید به این [لینک](#) مراجعه کنید.

^۴ Confusion Matrix

^۵ Transfer Learning

دقت کنید از آنجایی که می‌خواهیم مدل مقاله را با مدل بخش قبل مقایسه کنیم، تعداد ایپاک‌هایی که استفاده می‌کنید باید با بخش قبل برابر باشد.

۱-۴-۲. نتایج و ارزیابی (۲۰ امتیاز)

پس از آموزش، موارد گزارش شده در بخش ۱-۳-۲ را در این بخش نیز گزارش کنید. همچنین با توجه به نتایج به دست آمده عملکرد روش مقاله را با عملکرد مدل AlexNet مقایسه کنید.

- آیا معماری پیشنهادی توانسته است بر روی سرعت یادگیری مدل (دقت بیشتر در ایپاک کمتر) تأثیر بگذارد؟
 - توضیح دهید که استفاده از وزن‌های یک مدل پیش‌آموزش داده شده چگونه توانسته است عملکرد مدل را تحت تأثیر قرار دهد.
 - در معماری طراحی شده، دلیل جایگزینی لایه‌های کانولوشنی انتهایی VGGNet با دو لایه Inception را توضیح دهید. چگونه این انتخاب توانسته به یادگیری مدل کمک کند؟
 - دلیل استفاده از Global Pooling به جای لایه‌های Fully Connected در لایه انتهایی چیست؟
- (راهنمایی: به مقاله مراجعه کنید)

سوال ۲. طبقه‌بندی صحنه در تصاویر سنجش از دور

توسعه روزافزون تکنیک‌های یادگیری عمیق برای طبقه‌بندی تصاویر باعث شده است که در حوزه‌های مختلف به عنوان راه‌حل استفاده شوند. طبقه‌بندی صحنه در تصاویر سنجش از دور با وضوح بسیار بالا یا VHR یکی از مسائل چالش‌برانگیز است. شناسایی دقیق این صحنه‌ها (مانند مناطق مسکونی، فرودگاه‌ها، جنگل‌ها) کاربردهای حیاتی در برنامه‌ریزی شهری، مدیریت منابع و نظارت بر بلایا دارد.

در [مقاله مرجع](#)، یک مدل ترکیبی به نام CNN-MLP برای طبقه‌بندی تصاویر VHR ارائه شده است. هدف اصلی این پژوهش، استفاده از یک شبکه عصبی کانولوشنی از پیش‌آموزش دیده برای استخراج ویژگی و یک طبقه‌بند پرسپترون چندلایه بهینه‌سازی شده برای طبقه‌بندی نهایی است.

هدف این تمرین، پیاده‌سازی و ارزیابی معماری ارائه شده در مقاله CNN-MLP بر روی مجموعه داده UC-Merced است. شما تأثیر استفاده از داده‌افزایی و یادگیری انتقالی را بررسی خواهید کرد و عملکرد مدل مقاله را با یک مدل CNN ساده مقایسه می‌کنید.

۱-۱. آماده‌سازی مجموعه داده (۱۰ امتیاز)

در این بخش به آماده‌سازی مجموعه داده UC-Merced می‌پردازیم. این مجموعه داده یکی از سه دیتاست مورد استفاده در مقاله است.

مجموعه داده UC-Merced را دریافت کنید.

```
import kagglehub
path = kagglehub.dataset_download("abdulhasibuddin/uc-merced-land-use-dataset")
```

طبق مقاله، داده‌ها را به دو بخش آموزش (۸۰٪) و ارزیابی (۲۰٪) تقسیم کنید.

توزیع داده‌های هر کلاس را در مجموعه آموزش و آزمون بررسی کنید و یک هیستوگرام از تعداد داده‌های هر کلاس رسم کنید.

۱-۲. پیش‌پردازش داده‌ها (۱۵ امتیاز)

در این گام به آماده‌سازی مجموعه داده با کمک داده‌افزایی⁶ می‌پردازیم. داده‌افزایی مجموعه‌ای از تکنیک‌ها برای افزایش مصنوعی حجم و تنوع مجموعه داده آموزشی است. این کار از طریق اعمال تبدیلات جزئی و label-preserving بر روی تصاویر موجود (مانند چرخش، برش، تغییر مقیاس یا وارون‌سازی) انجام می‌شود.

هدف اصلی این کار، جلوگیری از بیش‌برازش⁷ است؛ یعنی وضعیتی که مدل به جای یادگیری الگوهای کلی، داده‌های آموزشی را حفظ می‌کند. با نشان دادن نسخه‌های متفاوتی از یک تصویر، ما مدل را وادار می‌کنیم تا ویژگی‌های مقاوم و اساسی‌تری را یاد بگیرد که به زاویه دید، نور یا موقعیت سوژه وابستگی کمتری دارند. در نتیجه، مدل تعمیم‌پذیری بهتری بر روی داده‌های جدید و دیده‌نشده خواهد داشت.

برای این بخش پیش‌پردازش‌های زیر را انجام دهید:

- طبق مقاله، اندازه تصاویر را برای ورودی مدل پیش‌آموزش‌دیده (Xception) به 299×299 تغییر دهید.
- مقادیر پیکسلی را به بازه مناسب برای مدل تبدیل کنید.
- توجه کنید که ورودی مدل Xception باید با میانگین و انحراف معیار مجموعه داده ImageNet نرمال‌سازی شود. (میانگین: $[0.406, 0.456, 0.485]$ ، انحراف معیار: $[0.225, 0.224, 0.229]$)
- روش‌های داده‌افزایی ذکر شده در مقاله (بخش ۲-۲-۱) را پیاده‌سازی کنید. این روش‌ها شامل چرخش، بزرگنمایی، وارون‌سازی افقی و وارون‌سازی عمودی هستند.
- دلیل انتخاب این روش‌ها را با توجه به ماهیت تصاویر سنجش از دور (که چرخش‌پذیر هستند) توضیح دهید.
- پس از اتمام مراحل، تعدادی از تصاویر مجموعه داده (مثلاً یک تصویر 'airplane') را به دلخواه انتخاب کرده و تصاویر تولید شده پس از اعمال داده‌افزایی را مانند شکل ۷ مقاله در گزارش نمایش دهید.

۱-۳. پیاده‌سازی (۲۰ امتیاز)

ابتدا، بخش استخراج ویژگی⁸ را پیاده‌سازی می‌کنیم. برای این کار، مدل Xception را که بر روی مجموعه داده ImageNet پیش‌آموزش‌دیده است، بارگذاری می‌کنیم. سپس، لایه‌های Fully Connected بالای شبکه (بخش طبقه‌بند) را حذف کرده و مطابق مقاله، وزن‌های مدل Xception را فریز می‌کنیم تا در طول آموزش تغییر نکنند و فقط به عنوان یک استخراج‌کننده ویژگی ثابت عمل کنند.

⁶ Data Augmentation

⁷ Overfitting

⁸ Feature Generation

سپس، بخش طبقه‌بند را پیاده‌سازی می‌کنیم. این بخش یک MLP بهینه‌شده⁹ است که مستقیماً به خروجی بخش استخراج ویژگی متصل می‌شود. این MLP به ترتیب شامل: Normalization، تابع فعال‌سازی Sigmoid، Dropout (با نرخ ۰.۴) برای جلوگیری از بیش‌برازش، و در نهایت تابع فعال‌سازی SoftMax برای طبقه‌بندی نهایی است.

کل مدل CNN-MLP را کامپایل کنید. مطابق مقاله، برای بخش MLP از بهینه‌ساز Adagrad استفاده کنید.

- یک summary از مدل تهیه و ارائه کنید و معماری و لایه‌های استفاده شده را توضیح دهید.
- مدل را با استفاده از داده‌های بخش ۱-۲ (با داده‌افزایی) برای ۵۰ اپیاک آموزش دهید.
- نرخ یادگیری مناسب را بدست آورید و به همراه سایر ابرپارامترها گزارش کنید.

۴-۱. ارزیابی (۳۰ امتیاز)

- نمودار تغییرات خطا و دقت بر روی مجموعه داده آموزش و آزمون را در طول آموزش گزارش و تحلیل کنید.
- ماتریس درهم‌ریختگی¹⁰ را برای مجموعه داده آزمون گزارش کنید. بررسی کنید که کدام کلاس‌ها بیشترین/کمترین تشخیص درست را دارند و جفت کلاس‌های پرتداخل کدامند.
- آیا معماری پیشنهادی توانسته است بر روی سرعت یادگیری مدل تأثیر بگذارد؟
- توضیح دهید که چرا نویسندگان به جای لایه‌های Fully Connected مرسوم در انتهای CNN، از یک MLP جداگانه به عنوان طبقه‌بند استفاده کرده‌اند؟ یک بار از لایه‌های Fully Connected پیش فرض در انتهای مدل استفاده کرده و دقت و نمودارهای آموزش را گزارش کنید.
- نقش Global Average Pooling قبل از ورود ویژگی‌ها به MLP چیست؟
- دلیل تأکید مقاله بر استفاده از بهینه‌ساز Adagrad برای MLP چیست؟

۵-۱. تحلیل و بهینه‌سازی

۱-۵-۱. تأثیر داده‌افزایی (۱۰ امتیاز)

برای سنجش میزان تأثیر داده‌افزایی بر روی نتایج، مدل CNN-MLP را مجدداً آموزش دهید، اما این بار از هرگونه تکنیک داده‌افزایی صرف نظر کنید (فقط تغییر سائز و نرمال‌سازی ورودی‌ها). دقت نهایی حاصل از این آزمایش را با دقت مدل آموزش دیده با داده‌افزایی مقایسه کنید. تحلیل خود را در این باره ارائه دهید.

⁹ Enhanced MLP

¹⁰ Confusion Matrix

۱-۵-۲. نقش بهینه‌ساز (۱۰ امتیاز)

برای ارزیابی نقش کلیدی بهینه‌ساز Adagrad در بخش MLP، مدل CNN-MLP بخش ۱-۳ را با همان تنظیمات (شامل داده‌افزایی)، اما با جایگزینی Adagrad با بهینه‌ساز متداول‌تر Adam آموزش دهید. دقت نهایی حاصل از بهینه‌سازی با Adam را با دقت Adagrad مقایسه کنید. که آیا انتخاب Adagrad واقعاً یک عامل بهینه‌شده و تأثیرگذار در عملکرد طبقه‌بند MLP بوده است، یا یک بهینه‌ساز مدرن‌تر می‌تواند نتایج مشابه یا بهتری را تولید کند.

۱-۵-۳. بهینه‌سازی توسط fine-tuning (۱۰ امتیاز)

در نهایت، برای بهینه‌سازی نهایی، از Fine-Tuning استفاده کنید. به جای فریز کردن کامل مدل پایه Xception، ۱۰ لایه آخر مدل را از حالت فریز خارج کنید تا وزن‌های آن‌ها در طول آموزش قابل به‌روزرسانی باشند. برای کامپایل مجدد، از بهینه‌ساز Adam همراه با یک نرخ یادگیری بسیار پایین استفاده کنید. سپس، مدل را مجدداً آموزش دهید. این فرآیند باعث می‌شود که وزن‌های لایه‌های انتهایی CNN به آرامی برای استخراج ویژگی‌های مناسب‌تر تنظیم شوند. دقت نهایی خود را گزارش کرده و بهترین ابرپارامترها (تعداد لایه‌های Unfreeze شده، نرخ یادگیری و بهینه‌ساز) را که توانسته است بالاترین دقت را کسب کند، شرح دهید.